

Industrialisation IA

Zacharie BUISSON - Mario DEFRANCE

Introduction



Agenda

Séance 1 - DS - Aurélien PACARD & Mario DEFRANCE / 14 janvier 2026

- Cours Data science
- Début des travaux pratiques 1

Séance 2 - DS - Aurélien PACARD & Mario DEFRANCE / 28 janvier 2026

- Travaux pratiques 1

Séance 1 - IA - Zacharie BUISSON / 13 Février 2026

- Cours Industrialisation IA
- Début des Travaux pratiques 2

Séance 3 - DS - Aurélien PACARD & Mario DEFRANCE / 4 mars 2026

- Travaux pratiques 1

Séance 4 - DS - Aurélien PACARD & Mario DEFRANCE / 6 mars 2026

- Finalisation travaux pratiques 2
- Soutenance des projets Data Science

Séance 2 - IA - Mario DEFRANCE / 17 Mars 2026

- Travaux Pratiques 2.


Séance 3 - IA - Zacharie BUISSON & Mario DEFRANCE / 14 Avril 2026

- Finalisation travaux pratiques 2
- Soutenance des projets industrialisation Modèle IA.





Contexte



- Vous avez construit (ou êtes en train de construire) votre modèle de Machine Learning / IA
 - **Il ne sert à rien !**

Pour le valoriser, vous allez :

- le rendre disponible aux utilisateurs à travers une API
- mettre en place une chaîne d'industrialisation automatisée



Livraison d'un projet IA : 2 mois à 3 ans

Pour une même fonctionnalité, plus le temps de livraison est long:

- Plus les utilisateurs se tourneront vers un service concurrent :
 - Exemple : ChatGPT interne vs ChatGPT externe
 - Problèmes de sécurité des données
 - Perte de clients
 - Déception des collègues qui préfèrent se tourner vers des prestataires externes, start-ups...
- Plus il faut payer le data scientist longtemps...
- ... plus le ROI du projet diminue
- Plus il faudra de temps pour itérer et corriger les erreurs en production et répondre aux nouveaux besoins métiers...
- Nécessité d'automatiser l'industrialisation pour livrer le plus vite possible



L'intérêt de la solution reste à démontrer en production !

- Besoin de monitoring des performances
 - Est-ce que la solution est utilisée ?
 - Est-ce que la solution fonctionne ?
 - Est-ce que la solution est performante ?
- Besoin de feedback utilisateurs (pas forcément évident en IA...)
 - Biais de sélection: comment savoir si un prospect qui n'a pas pris un prêt chez nous l'aurait payé ?
 - Comment savoir si un utilisateur à utiliser la prédiction de l'IA ? sans ajouter de surcharge ?



Vous n'êtes pas non plus les seuls développeurs dans l'entreprise :

Dans une entreprise, il y a des personnes chargées de la production : ce sont les personnes du SI (système d'information) ;

Ils gèrent les outils informatiques au niveau de l'entreprise :

- Site WEB de l'entreprise
- Outils pour les commerciaux
- Dashboards...

Votre modèle d'IA doit s'intégrer dans cet environnement complexe :

- un héritage technique existe et les solutions modernes doivent s'intégrer
- des contraintes pour rendre le système homogène doivent être mises en place (sécurité, qualité de code..)

Infrastructure d'entreprise



Choix 1 : Architecture Cloud

Une architecture distante



Avantages

- Utilisation à la demande (*pay what you use*)
- Services pré existants (*délégation software*)
- Pas de serveurs (*délégation hardware*)



Inconvénients

- Dépendance à services externes : obligation de montée de version, suppression de service
- Protection des données, notamment extra UE



 Azure (Microsoft)



 AWS (Amazon)



 OVH



Choix 2 : Architecture on premise

Une architecture à la maison



Avantages

- Flexibilité hardware & software : sur mesure aux besoins
- Indépendance aux organismes externes
- Sécurité gérée en interne, pas de problèmes de transit de données



Inconvénients

- Mise à jour hardware et software à la main de l'entreprise : ajout de puissance de calcul manuel...
- Recrutement de personnel pour maintenir le système




Docker



Kubernetes

Le cycle de vie d'un projet IT en production



Data Scientist



Data Scientist, Dev Ops



Equipe Infrastructure (App Ops, Dev Ops)



Equipe Infrastructure (App Ops, Dev Ops)



Livraison d'une première version dans un environnement industriel



Livraison de l'ensemble des briques composants le système final



Verifier que l'infrastructure répond correctement



Mise à disposition des utilisateurs



Instable



Moyennement stable



Stable



Stable



Tests d'intégration
Tests de masse



Tests de masse
Tests fonctionnel



Tests de charge
Tests d'intrusion
Tests fonctionnels



Tests d'intrusion
Smoke tests



Bases de données relationnelles

Modèle historique dans les banques et assurances



SQL : Structured Query Language

SQL

Approche structurée

- Système polyvalent - rapide en lecture et écriture ;
- Pas d'unicité dans les observations ;
- Optimisé pour le brassage de données : jointure, calculs de variables en fonction de caractéristiques d'intérêt.



Oracle DataBase



PostgreSQL



NoSQL : Not only Structured Query Language

Approche non structurée

- Optimiser en lecture - pas écriture ;
- Accès aux données par clé (rapide), unicité des clés ;
- Utilisation sur de la donnée brute, en production.



Microsoft
SQL Server



mongoDB



Bases de données non relationnelles

Modèle novateur dans les banques et assurances

- Stockage documentaire : note de procédure interne, contrats client...
- Vidéo : caméra de surveillance, pièces de sinistres ;
- Voix : call center.



GED : Gestion Electronique
de Documents




Amazon S3

Microsoft Azure
Blob Storage



Programmation, bonnes pratiques et comment construire un logiciel utile

Quelques étapes pour la réussite d'un projet IA en collaboration





PEP8 : Python Enhancement Proposal

Norme de programmation Python

Ensemble de pratiques pour faire du code dans les standards Python

- Respecter la snake_case ;
- Faire des doctrines ;
- Ne pas laisser d'éléments non utilisés...



But : Normalisation du code, possibilité de le rendre compréhensible de tous...



Programmation Orientée Objet

Synthèse de fonctions pour suivre dans le temps



Exemple d'objet : Client de Banque

Attributs : Montant sur le compte, nom, prénom



Objet hérité : Client crédit agricole

Attributs : Nom de l'agence, caisse régionale...



But : Regrouper et normaliser des éléments avec des caractéristiques communes, suivre l'état d'un élément...



Programmation SOLID

Comment construire une bonne fonction ?

Single Responsibility Principle

Chaque fonction doit avoir une seule fonctionnalité

Open / Closed Principle

Ouvert à l'extension, fermé à la modification

Liskov Substitution Principle

Les classes héritées doivent avoir les méthodes de la classe mère fonctionnelles

Interface segregation principle

Une classe ne doit avoir que des fonctions utiles à sa classe

Dependency Inversion Principle

Non détaillé, pas le plus important...



But : Avoir des fonctions simples à tester, limiter les erreurs...

3 principaux modes de livraison de code



Packaging de code

Mise à disposition du code en ligne



Comment faire ?

Code brut livré dans un repertoire git


Construction d'une Wheel

Déploiement de la wheel en ligne :

- PyPI
- Conda Forge
- Artifactory interne



But : Utilisation et installation d'un code à la demande et à la main d'un utilisateur.



Batching & CronJob

Publier une application à lancement auto.



Comment faire ?

Code brut livré dans un repertoire git

Encapsulation dans un outil

- CronJob
- Lambda + EventBridge sur AWS
- DataBricks
- Linux : Cron
- Windows : Task Scheduler



But : Déploiement / installation en production, lancement automatisé chaque jour, à intervalle régulière, envoi notification succès / échec.



API

Publier une application en temps réel



Comment faire ?

Code brut livré dans un repertoire git

Construction d'une API

Encapsulation dans un conteneur Docker

Déploiement du docker sur un serveur

- ArgoCD (on premise)
- AWS ECS (cloud)
- Azure Machine Learning



But : Déploiement / installation en production, application disponible pour un appel en temps réel.



Comment Interagir avec une API ?

API et requêtes..

Quatre types de requêtes principales :



GET

Sert à récupérer des informations directement



POST

Sert à envoyer une information (sensible) à l'application



PUT

Enregistrer une donnée dans une BDD ou la mettre à jour




DELETE

Supprimer une donnée dans une base de données

Documentation : OpenAPI (swagger)

Fichiers .yaml, ou .json qui décrit les façons possibles pour interagir avec un API



Comment livrer un logiciel

Le code fonctionne sur mon ordinateur mais pas en production que faire ?



Créer un plat avec une recette de cuisine

Ecrire la recette de cuisine

Décrire les étapes permettant de créer la recette.

Faire la recette de cuisine

Exécuter les étapes une à une pour construire un plat.

Avoir un plat préparé

Avoir un plat à disposition, prêt à être utilisé.



Créer une application avec Docker

Ecrire la recette de l'application

Décrire les étapes permettant de reconstruire l'application (DockerFile)

Faire la recette de l'application

Exécuter les étapes une à une pour construire l'application. (Image Docker)

Avoir une application préparée

Avoir une application déployée, dans un espace isolé et performant. (Conteneur)

Commande : pas de commande

Il faut juste rédiger un DockerFile

Commande : docker build

Peut être une image stockée en local ou dans un repertoire en ligne : artifactory, Docker Hub, AWS ECR.

Commande : docker run

Peut s'utiliser en local ou sur un serveur avec Kubernetes

Points Critiques à surveiller :



Gestion de la charge de l'application
Comment gérer un afflux d'utilisateurs ?



Redémarrer l'application si échec
Cela permet de maintenir une application fonctionnelle




Gérer les mises à jour
Comment mettre à jour une application sans tout couper ?




Tester mon application
Comment s'assurer que mon application soit correcte ?

Scalability

Vertical scaling



Horizontal scaling





Intégration continue

Comment intégrer efficacement des modifications dans une application de production ?

Evaluation de la qualité de code



Solutions Open Source

- *Flake8 : Formateur de code*
- *Black : Formateur de code*
- *Ruff : Formateur de code (rapide)*
- *PyLint : Formateur de code*
- *Isort : Formateur des imports*



But : S'assurer que le code de l'application sera compris par tous.

Tests unitaires

- Vérifier que chaque fonction de son code marche correctement
- Tester sur des cas classiques et des cas limites.



But : S'assurer que le code fonctionne et que l'on ne « casse » rien qui fonctionnait.

Construction des artefacts

- Construction de l'image contenant l'API ou d'un .zip ;
- Stockage de l'artefact créé dans un répertoire.




DOCKER



But : Faciliter et normaliser la livraison du code.

1. tests de sécurité Xray CVE : vulnérabilités de l'application + test d'injection de code dans les
2. déploiement de l'application dans un environnement
3. promotion vers environnements ultérieurs de DEV à PROD



The screenshot shows the Docker Hub page for the `python:3.13` image. It includes the Python logo, the image name, and various statistics. The 'Layers (12)' section is expanded, showing the buildpack-deps layer and the python:3.13 layer. The 'Vulnerabilities (159)' section is also visible, showing a table of CVEs.

CVE ID	Severity	Fixable	Present in	Affected package(s)
CVE-2022-49043	8.1	Yes	Python	deb / debian/libxml2
CVE-2024-56171	7.8	Yes	Python	deb / debian/libxml2

O'RELLY®

Deploy First, Pray Later

god abandoned this
pipeline long ago.

Some Random guy on X
@observer_ofyou



Application à l'IA



Suivi et monitoring de la viabilité de l'application en production

Ne pas laisser son application dépérir en production...



Suivre le comportement de son application :

Est-ce que l'application fonctionne ?

Fait-elle face à des imprévus ? Est-elle utilisée ?


S'est-elle correctement intégrée dans le reste du SI ?





Suivi et monitoring du drift en production

Ne pas laisser son application dégrader en production...



Source: <https://arxiv.org/pdf/2004.05785.pdf>

Recueillir des retours des utilisateurs :

*Pas possible : un fraudeur ne va pas faire un feedback
A prendre en compte dès la conception du projet*



Surveiller la cohérence statistique d'un modèle

d'IA / ML :

*Attention aux données plus représentatives de la réalité
Nécessite un ré-entraînement ou des correctifs.*



Pipelines d'IA

Entraînement automatique de modèles

- Script d'entraînement d'un modèle d'IA, prévu de A à Z.
- Peut être déclenché automatiquement ou à dates régulières
- Permet d'itérer rapidement et de créer de nouveaux cas d'usage similaire




Script d'entraînement

Création de blocs thématiques réutilisables au besoin



Creating & Running ML Pipeline



Azure Machine Learning
Designer